CẢI THIỆN PHÂN ĐOẠN CÂY NGÔ VÀ CỎ DẠI TRÊN ẢNH UAV ĐA PHỔ BẰNG SEGFORMER VỚI PRETRAINED MIT-B0

Nguyễn Thị Thanh Thảo[1,*],

[1]*Khoa Công nghệ Thông tin,*

Trường Đại học Công Thương Thành phố Hồ Chí Minh

[*]Email: 1001260025@huit.edu.vn,

Ngày nhận bài..... ; Ngày chấp nhận đăng: xxx, 2026

Tóm tắt

Phát hiện cỏ dại và phân đoạn cây trồng từ ảnh UAV là nhiệm vụ quan trọng trong nông nghiệp chính xác. Ảnh đa phổ bổ sung thông tin ngoài RGB, trong khi mô hình segmentation cần cân bằng chất lượng dự đoán với chi phí tính toán. Nghiên cứu này xây dựng mô hình semantic segmentation dựa trên SegFormer với encoder MiT-B0 pretrained, điều chỉnh đầu vào từ RGB sang năm băng R, G, B, NIR và RE, đồng thời thêm nhánh Low-Level Feature Refinement để hợp nhất thông tin không gian–phổ độ phân giải cao với đặc trưng ngữ nghĩa đa tỉ lệ. Trên test set WeedsGalore, mô hình 5-band đạt 85.49 ± 0.30% mIoU qua năm seed, cao hơn 2.59 điểm so với mốc DeepLabV3+ 82.90% được công bố trên cùng official test set. Mô hình sử dụng 3.66M tham số và 17.09G FLOPs, so với 39.76M tham số và 173.82G FLOPs của baseline. Trên PhenoBench, mô hình được huấn luyện độc lập đạt 89.83% mIoU trên validation split khi đánh giá ở độ phân giải gốc 1024×1024. Do nhãn của test split PhenoBench không được công khai, nghiên cứu không báo cáo test mIoU cho bộ dữ liệu này; kết quả validation không được xem là kết quả test hoặc phép đo cross-dataset transfer. Kết quả trên WeedsGalore cho thấy tiềm năng của kiến trúc trong việc cải thiện phân đoạn cây trồng–cỏ dại trên ảnh UAV đa phổ với số lượng tham số thấp; các so sánh latency cần được đọc theo đúng giao thức đo đã sử dụng.

Từ khóa: semantic segmentation; multispectral UAV imagery; SegFormer; MiT-B0; multi-scale feature fusion; lightweight segmentation.

1. Giới thiệu

Nông nghiệp chính xác ngày càng ứng dụng các phương tiện bay không người lái (UAVs) và các công nghệ imaging tiên tiến để hỗ trợ crop monitoring, field management và targeted weed control. So với RGB imagery truyền thống, multispectral UAV imagery cung cấp thêm spectral information ngoài visible range, đặc biệt là các band near-infrared (NIR) và red-edge (RE) [1], có thể cung cấp complementary information về vegetation characteristics [2]. Trong crop production, việc xác định chính xác crops và weeds ở pixel level có giá trị trong việc ước tính weed distribution, monitoring crop conditions và hỗ trợ các site-specific agricultural operations tiếp theo. Do đó, semantic segmentation

của UAV imagery thành các vùng background, crop và weed đã trở thành một research problem quan trọng trong precision agriculture, đặc biệt trong các scenarios yêu cầu reliable pixel-level information.

Mặc dù có ý nghĩa thực tiễn, crop–weed segmentation từ UAV imagery vẫn còn nhiều thách thức. Weeds có thể xuất hiện dưới dạng các vùng nhỏ, mảnh, có hình dạng không đều và có thể nằm gần hoặc xen lẫn với crop plants. Đặc biệt, visual appearance của crops và weeds có thể tương đồng về color, texture và shape, khiến boundaries của chúng khó phân biệt nếu chỉ sử dụng thông tin RGB. Bài toán trở nên khó khăn hơn khi input imagery chứa các objects có spatial scales khác nhau đáng kể. Các vùng weed nhỏ và narrow boundaries có thể bị suy yếu hoặc mất đi khi feature maps liên tục được downsample trong quá trình feature extraction. Đồng thời, một segmentation model được thiết kế cho UAV-based applications phải xem xét computational efficiency, vì các high-capacity architectures có thể yêu cầu đáng kể về memory, computation và inference time, từ đó hạn chế khả năng deployment trên edge hoặc UAV platforms.

Các phương pháp semantic segmentation hiện có thể tạo ra những đánh đổi khác nhau giữa năng lực biểu diễn và chi phí tính toán. DeepLabV3+ kết hợp ngữ cảnh đa tỉ lệ với decoder tinh chỉnh biên [5]. Trên thiết lập semantic segmentation ba lớp (uni-weed) của WeedsGalore [3], bài báo gốc báo cáo DeepLabV3+ với đầu vào MSI đạt 82.90% mIoU trên official test set. Giá trị này được dùng làm mốc tham chiếu cho so sánh test ở Bảng 4 và Bảng 6; các con số validation của mô hình đề xuất ở Bảng 2 và Bảng 5 được báo cáo riêng, không so sánh trực tiếp với mIoU test của baseline.

Những quan sát này thúc đẩy việc xây dựng một mô hình nhẹ khai thác cả thông tin đa phổ và đặc trưng ngữ nghĩa đa tỉ lệ. Trong nghiên cứu này, chúng tôi sử dụng SegFormer với encoder MiT-B0 pretrained [7], điều chỉnh lớp đầu vào từ RGB sang năm băng R, G, B, NIR và RE, rồi hợp nhất các đặc trưng đa tỉ lệ với một nhánh xử lý trực tiếp đầu vào ở độ phân giải H/2. Nhánh này được thiết kế nhằm duy trì thêm chi tiết không gian–phổ cho các vùng Weed nhỏ và ranh giới Crop–Weed, đồng thời được đánh giá cùng chi phí tham số, FLOPs, latency và calibration.

Nghiên cứu xem xét bốn câu hỏi: (1) SegFormer với encoder MiT-B0 pretrained có đạt hiệu năng phân đoạn cạnh tranh với chi phí tính toán thấp hơn baseline ResNet50–DeepLabV3+ hay không? (2) Multi-scale feature fusion và nhánh Low-Level Feature Refinement có liên quan như thế nào đến hiệu năng phân đoạn? (3) Đầu vào RGB + NIR + RE cải thiện kết quả ra sao so với RGB-only, đặc biệt ở lớp Weed? (4) Kết quả thay đổi thế nào qua năm random seeds, và cùng hướng thiết kế kiến trúc hoạt động ra sao khi được huấn luyện và đánh giá độc lập trên PhenoBench?

Các đóng góp của nghiên cứu gồm: (1) điều chỉnh MiT-B0 pretrained từ đầu vào RGB sang năm băng R, G, B, NIR và RE; (2) kết hợp đặc trưng đa tỉ lệ của SegFormer với một nhánh convolution độ phân giải cao xử lý trực tiếp đầu vào đa phổ; (3) đánh giá chất lượng phân đoạn, chi phí tính toán và độ ổn định qua năm seed trên WeedsGalore, đồng thời so sánh RGB-only với 5-band; và (4) đánh giá calibration bằng Temperature Scaling, cùng một thực nghiệm huấn luyện độc lập trên PhenoBench. Chúng tôi không xem thí nghiệm PhenoBench là transfer trực tiếp từ checkpoint WeedsGalore, cũng không tuyên bố nguyên lý high-resolution refinement tự thân là mới; điểm khảo sát là cách tích hợp cụ thể với MiT-B0 5-band và kết quả thực nghiệm.

Phần còn lại của paper được tổ chức như sau. Phần 2 trình bày các nghiên cứu liên quan về semantic segmentation cho UAV và multispectral imagery, các segmentation methods dựa trên CNN và Transformer, cũng như multi-scale feature representation. Phần 3 trình bày architecture được đề xuất, bao gồm việc adaptation MiT-B0 sang five-band input và feature-fusion design. Phần 4 mô tả experimental settings và báo cáo results trên WeedsGalore và PhenoBench, bao gồm ablation studies, accuracy–efficiency analysis, calibration và qualitative evaluation. Cuối cùng, phần 5 tóm tắt các findings chính, thảo luận về limitations của study và đưa ra các directions cho future research.

2. Nghiên cứu liên quan

Semantic segmentation gán nhãn cho từng pixel và được ứng dụng trong phân tích ảnh UAV, viễn thám và nông nghiệp chính xác. Với crop–weed segmentation, mô hình cần phân biệt Background/Soil, Crop và Weed ở mức pixel. Các kiến trúc encoder–decoder như DeepLabV3+ kết hợp thông tin ngữ cảnh đa tỉ lệ với decoder nhằm phục hồi chi tiết biên [5]. Vì vậy, khi sử dụng các mô hình làm baseline, cần tách bạch rõ giá trị được báo cáo trên validation và test set.

Castellano et al. [6] proposed a lightweight Vision Transformer for multispectral drone imagery and described how RGB-pretrained weights can be adapted to non-visible spectral bands. Their experiments use the WeedMap dataset and a different architecture and evaluation setup; therefore, their reported numbers are not directly comparable to the WeedsGalore results in this study. Spectral indices and attention/gating modules should likewise be assessed through controlled ablation rather than assumed to improve every configuration.

SegFormer là kiến trúc semantic segmentation kết hợp hierarchical Transformer encoder MiT với decoder MLP nhẹ và tạo đặc trưng đa tỉ lệ [7]. Trong nghiên cứu này, MiT-B0 được khởi tạo từ checkpoint pretrained nvidia/mit-b0, ba kernel đầu vào RGB được giữ lại, còn hai kernel NIR và RE được khởi tạo bằng trung bình các kernel RGB tương ứng trước khi fine-tune. Đây là cách thích nghi checkpoint RGB cho đầu vào năm kênh; nó không thay đổi đóng góp cốt lõi của SegFormer gốc.

Các feature sâu chứa ngữ nghĩa và ngữ cảnh nhưng có độ phân giải thấp hơn; các đường truyền độ phân giải cao giúp bảo toàn vị trí, hình dạng và biên đối tượng. BiSeNet [11] là ví dụ về việc tách spatial path và context path, còn DeepLabV3+ [5] dùng decoder để tinh chỉnh ranh giới. Do đó, ý tưởng khai thác thông tin không gian độ phân giải cao không phải mới. Khác biệt trong nghiên cứu này là nhánh convolution nhỏ xử lý trực tiếp ảnh đầu vào 5-band tại H/2 rồi nối với feature đa tỉ lệ của MiT-B0 trước bước refinement và classifier. Phần thực nghiệm cần đo đóng góp của nhánh bằng ablation và tránh diễn giải vượt quá các kết quả hiện có.

3. Phương pháp đề xuất

3.1. Tập dữ liệu

Nghiên cứu sử dụng WeedsGalore làm bộ dữ liệu chính cho training, model selection, ablation và đánh giá. PhenoBench được dùng trong một thực nghiệm huấn luyện–đánh giá độc lập: mô hình được huấn luyện trên train split và đánh giá trên validation split của chính PhenoBench. Nhãn của test split PhenoBench không được công khai trong bộ dữ liệu dùng ở nghiên cứu này, nên không thể tính metric test cục bộ; các kết quả PhenoBench được báo

cáo dưới đây đều là validation results. Không sử dụng checkpoint huấn luyện trên WeedsGalore để đánh giá PhenoBench, do đó kết quả này không phải phép đo cross-dataset transfer.

WeedsGalore là bộ dữ liệu UAV đa phổ được công bố tại WACV 2025 [3], gồm 156 ảnh 600×600 với năm band R, G, B, NIR và RE. Tập dữ liệu có 104 ảnh train, 26 ảnh validation và 26 ảnh test theo split được sử dụng trong nghiên cứu. Annotation gốc phân biệt maize cùng bốn nhóm cỏ dại (Amaranth, Barnyard Grass, Quickweed và Weed Other); trong thí nghiệm này, các nhóm cỏ dại được gộp thành lớp Weed để tạo bài toán semantic segmentation ba lớp Background, Crop và Weed. GSD của ảnh là khoảng 2.5 mm/pixel, không phải cm/pixel.

Theo các mask và split dùng trong nghiên cứu, tập train gồm 1.461 vùng Crop và 6.512 vùng Weed; validation gồm 451 vùng Crop và 1.808 vùng Weed; test gồm 257 vùng Crop và 1.711 vùng Weed. Bốn loại cỏ dại trong annotation gốc được gộp thành một lớp Weed trong các thực nghiệm ba lớp, nhưng vẫn được thống kê riêng theo loại trong mô tả dataset. Split train/validation/test được giữ cố định giữa các cấu hình để hạn chế sai khác do phân chia dữ liệu.

PhenoBench [9] là bộ dữ liệu UAV trên cây sugar beet, được công bố trên IEEE Transactions on Pattern Analysis and Machine Intelligence năm 2024. Ảnh RGB và các annotation được phát hành ở kích thước 1024×1024; GSD khi thu nhận khoảng 1 mm/pixel. Semantic mask gốc sử dụng các ID 0=Background/Soil, 1=Crop, 2=Weed, 3=partial-crop và 4=partial-weed; hai nhãn partial biểu thị cây có dưới 50% diện tích nhìn thấy. Theo thống kê dùng trong bài, dữ liệu có trung bình 8.55 crop instances/image và 5.70 weed instances/image. Mô hình được huấn luyện riêng trên train split PhenoBench (1,407 ảnh) và đánh giá trên validation split (772 ảnh) tại các thiết lập đầu vào 512×512 và 1024×1024. Kết quả không dùng checkpoint đã huấn luyện trên WeedsGalore.

Bảng 1 phân biệt annotation gốc với không gian nhãn dùng để báo cáo metric. Với WeedsGalore, bốn nhóm cỏ dại gốc được gộp thành lớp Weed trong bài toán ba lớp. Với PhenoBench, các mask gốc có ID 0–4 được ánh xạ sang ba lớp báo cáo như sau: 0→Background/Soil, 1→Crop, 2→Weed, 3 (partial-crop)→Crop và 4 (partial-weed)→Weed. Vì vậy, hai nhãn partial được gộp vào lớp đối tượng tương ứng, không được loại bỏ bằng ignore mask trong cấu hình này. GSD được ghi thống nhất theo mm/pixel: 2.5 đối với WeedsGalore và khoảng 1 đối với PhenoBench.

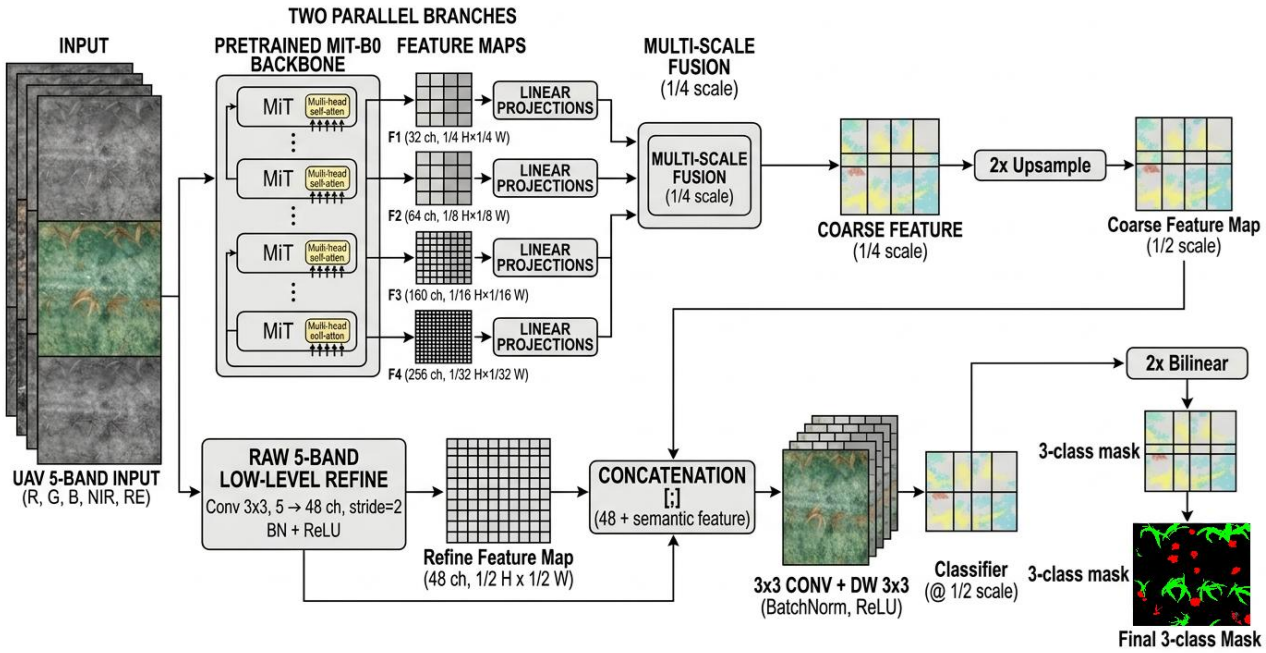
Bảng 1. Đặc điểm bộ dữ liệu gốc và không gian lớp được dùng trong các thực nghiệm.

Dataset	Publication year	Crop	GSD (mm/pixel)	Input modality	Original labels / weed types	Classes in this study	Crop instances/ image	Weed instances/ image	Resolution
PhenoBench	2024	Sugar beet	≈1	RGB	BG, Crop, Weed, partial-crop, partial-weed	3 target classes: BG/Soil, Crop, Weed	8.55	5.70	1024×1024
WeedsGalore	2025	Maize	2.5	5-band MSI	Maize + 4 weed groups	3: Background, Crop, Weed (4 weed groups merged)	13.91	64.30	600×600

3.2. Phương pháp đề xuất

Nghiên cứu xây dựng mô hình dựa trên SegFormer với MiT-B0 pretrained làm backbone. So với baseline ResNet50–DeepLabV3+, MiT-B0 được lựa chọn nhằm giảm chi phí tính toán trong khi vẫn cung cấp đặc trưng hierarchical multi-scale. Để phù hợp với dữ liệu WeedsGalore, kiến trúc được điều chỉnh theo hai hướng chính: (1) mở rộng đầu vào từ RGB 3-band sang 5-band RGB–NIR–RE và (2) bổ sung nhánh tinh chỉnh đặc trưng cấp thấp để khai thác trực tiếp thông tin không gian–phổ ở độ phân giải cao.

Hình 3.2 tóm tắt luồng xử lý. Với đầu vào X có kích thước 5×H×W, MiT-B0 tạo bốn feature map F1–F4 lần lượt có 32, 64, 160 và 256 kênh ở độ phân giải H/4, H/8, H/16 và H/32. Nhánh multi-scale projection đưa các feature về cùng số chiều, upsample về H/4 và nối theo chiều kênh. Feature đa tỉ lệ sau đó được upsample lên H/2. Song song, Low-Level Feature Refinement áp dụng Conv 3×3, stride 2, 5→48 kênh, Batch Normalization và ReLU để tạo feature 48×H/2×W/2. Hai feature được concatenation tại H/2, tiếp tục qua Conv 3×3 + BN + ReLU, Depthwise Conv 3×3 + BN + ReLU và classifier. Logits ở H/2 được bilinear upsampling 2× về H×W để tạo mask ba lớp. Luồng này cần được giữ nhất quán với sơ đồ và implementation.



Hình 3.2. Luồng tensor của SegFormer/MiT-B0 5-band và nhánh Low-Level Feature Refinement (kích thước đầu ra được ghi theo tỉ lệ so với H×W).

3.2.1. Điều chỉnh MiT-B0 cho đầu vào 5-band

SegFormer nguyên bản được thiết kế cho ảnh RGB với ba kênh đầu vào, trong khi WeedsGalore cung cấp năm kênh R, G, B, NIR và RE. Do đó, lớp input projection của MiT-B0 được mở rộng để nhận năm kênh thay vì ba kênh.

Thay vì khởi tạo lại toàn bộ backbone, ba kernel tương ứng với RGB được giữ nguyên từ pretrained MiT-B0. Hai kernel mới tương ứng với NIR và RE được khởi tạo bằng giá trị trung bình của các kernel RGB tương ứng, sau đó toàn bộ backbone được fine-tune trên WeedsGalore. Cách thiết lập này cho phép mô hình tận dụng biểu diễn pretrained từ RGB, đồng thời học thêm đặc trưng từ hai spectral bands mới.

Đây là một điều chỉnh của chúng tôi đối với kiến trúc SegFormer gốc, do đó cách mở rộng input projection và initialization của hai kênh NIR–RE cần được mô tả rõ trong phương pháp.

3.2.2. Hợp nhất đặc trưng đa tỉ lệ

MiT-B0 tạo ra bốn feature maps có số kênh lần lượt là 32, 64, 160 và 256, với độ phân giải tương ứng H/4 x W/4, H/8 x W/8, H/16 x W/16 và H/32 x W/32. Các đặc trưng này chứa thông tin ở các mức khác nhau: feature ở các stage nông bảo toàn nhiều thông tin không gian, trong khi feature ở các stage sâu chứa ngữ nghĩa và context ở phạm vi rộng.

Chúng tôi kế thừa cơ chế multi-scale feature fusion của SegFormer. Cụ thể, mỗi feature map được đưa qua Linear Projection để đưa về không gian đặc trưng chung, sau đó được upsample về độ phân giải ¼ và concatenated theo chiều kênh. Do cơ chế này đã được trình bày trong SegFormer, nghiên cứu không lặp lại các công thức của module fusion gốc, mà tập trung mô tả cách feature sau fusion được sử dụng trong kiến trúc đề xuất.

Feature đa tỉ lệ sau đó được upsample lên độ phân giải ½ để kết hợp với nhánh tinh chỉnh đặc trưng cấp thấp. Thiết kế này cho phép mô hình kết hợp semantic features từ MiT-B0 với thông tin chi tiết được lấy trực tiếp từ ảnh 5-band.

3.2.3. Nhánh tinh chỉnh đặc trưng cấp thấp

Mặc dù MiT-B0 có khả năng trích xuất đặc trưng phân cấp (hierarchical features) ở nhiều mức độ phân giải, quá trình nhúng đặc trưng (embedding) và giảm độ phân giải (downsampling) trong backbone có thể làm mất một phần thông tin không gian chi tiết. Hạn chế này đặc biệt đáng lưu ý đối với các đối tượng có kích thước nhỏ như cỏ dại (Weed), các lá có hình dạng mảnh và vùng ranh giới giữa cây trồng (Crop) và cỏ dại (Weed).

Để hạn chế sự mất mát thông tin ở các tầng sâu, chúng tôi bổ sung một nhánh tinh chỉnh đặc trưng (Low-Level Feature Refinement) nhằm xử lý trực tiếp ảnh đầu vào gồm 5 băng phổ. Không phụ thuộc hoàn toàn vào các đặc trưng được trích xuất qua backbone, nhánh này tạo một đường truyền ngắn từ đầu vào đến giai đoạn hợp nhất đặc trưng, qua đó duy trì tốt hơn các thông tin không gian–phổ ở độ phân giải cao. Đặc trưng thu được từ nhánh này sau đó được kết hợp với các đặc trưng phân cấp của MiT-B0, giúp mô hình tăng cường khả năng biểu diễn các cấu trúc nhỏ và ranh giới đối tượng.

Với input $X \in R^{5\times H\times W}$, nhánh này sử dụng một convolution 3 × 3, stride 2, để chuyển số kênh từ 5 lên 48, tiếp theo là Batch Normalization và ReLU:

$$F_{LL} = ReLU\left(BN\left(Conv_{3\times3}^{5\to48,s=2}(X)\right)\right) \quad (1)$$

Feature từ nhánh tinh chỉnh có kích thước 48×H/2×W/2. Đây là đường truyền trực tiếp từ ảnh đầu vào 5-band đến giai đoạn fusion, bổ sung chi tiết không gian–phổ cho hierarchical features của MiT-B0. Nhánh này làm tăng ít tham số nhưng tăng FLOPs đáng kể do feature được xử lý ở độ phân giải H/2; vì vậy, hiệu quả cần được đánh giá đồng thời trên accuracy và computation.

3.2.4. Hợp nhất đặc trưng và dự đoán cuối

Sau khi hợp nhất đặc trưng hoàn tất, feature từ MiT-B0 được đưa về cùng độ phân giải với feature F_{LL}và thực hiện concatenation theo chiều kênh. Phép fusion này cho phép kết hợp đặc trưng ngữ nghĩa đa tỉ lệ từ backbone với thông tin không gian–phổ chi tiết được trích xuất trực tiếp từ ảnh 5-band, tạo feature đầu vào cho giai đoạn refinement.

$$F_{cat} = Concat(Upsample(F_{MS}, 2), F_{LL}) \quad (2)$$

Feature sau concatenation tiếp tục được xử lý qua một convolution 3 × 3 kết hợp Batch Normalization và ReLU, sau đó là Depthwise Convolution 3 × 3 cùng Batch Normalization và ReLU. Hai bước này giúp tinh chỉnh feature sau fusion, đồng thời Depthwise Convolution được sử dụng để giảm chi phí tham số và phép tính của phần decoder so với convolution thông thường.

Feature sau refinement được đưa qua classifier để tạo logits tương ứng với ba lớp Background, Crop và Weed. Logits sau đó được bilinear upsampling về kích thước không gian ban đầu của ảnh để tạo segmentation mask cuối cùng. Các phép toán convolution, Depthwise Convolution, classifier và bilinear upsampling đều sử dụng các phép biến đổi chuẩn, do đó phần này chỉ tập trung mô tả các thành phần và cách chúng được tích hợp trong kiến trúc đề xuất.

3.2.5. Hàm mất mát và trọng số lớp

Do sự phân bố pixel giữa ba lớp Background, Crop và Weed có sự chênh lệch, đặc biệt lớp Weed thường chiếm diện tích nhỏ hơn so với các lớp còn lại, hàm mất mát cần được thiết lập để hạn chế ảnh hưởng của sự mất cân bằng lớp trong quá trình huấn luyện. Trong nghiên cứu này, Weighted Cross-Entropy Loss được kết hợp với Soft Dice Loss nhằm đồng thời duy trì khả năng phân loại ở mức pixel và cải thiện mức độ chồng lấp giữa prediction và ground truth. Đây đều là các loss function phổ biến trong semantic segmentation, do đó chỉ các thiết lập cụ thể của nghiên cứu được trình bày dưới đây.

Đối với Weighted Cross-Entropy Loss, class weights được thiết lập lần lượt cho Background, Crop và Weed như sau:

$$w = [0.9, 1.0, 1.3] \qquad (3)$$

Trong đó, lớp Weed được gán trọng số cao hơn nhằm tăng mức đóng góp của các pixel thuộc lớp này trong quá trình tối ưu. Cách thiết lập này phù hợp với đặc điểm của dữ liệu, khi Weed thường xuất hiện với diện tích nhỏ và dễ bị chi phối bởi các lớp có số lượng pixel lớn hơn.

Soft Dice Loss được sử dụng như một thành phần bổ sung nhằm tăng cường khả năng tối ưu mức độ tương đồng về vùng giữa prediction và ground truth. Thành phần này đặc biệt có ý nghĩa đối với các đối tượng có diện tích nhỏ hoặc hình dạng mảnh như Weed, nơi những sai lệch cục bộ có thể ảnh hưởng đáng kể đến mức độ chồng lấp của vùng phân đoạn.

Hai thành phần loss được kết hợp với hệ số được thiết lập trong nghiên cứu như sau:

$$L = 0.7L_{CE} + 0.3L_{Dice} \quad (4)$$

Trong đó, Weighted Cross-Entropy Loss giữ vai trò chính trong quá trình tối ưu dự đoán ở cấp pixel, trong khi Soft Dice Loss bổ sung mục tiêu cải thiện sự tương đồng về vùng. Tỷ lệ 0.7 : 0.3 được sử dụng xuyên suốt quá trình training và được giữ cố định trong các thí nghiệm.

Phương pháp đề xuất kế thừa backbone MiT-B0 và cơ chế multi-scale feature fusion của SegFormer, đồng thời được điều chỉnh cho dữ liệu multispectral thông qua hai thay đổi chính: mở rộng input từ 3 lên 5 spectral bands và bổ sung nhánh Tinh chỉnh đặc trưng cấp thấp. Sự kết hợp này cho phép mô hình khai thác hierarchical semantic features từ Transformer cùng với spatial–spectral details được duy trì trực tiếp từ ảnh 5-band. Ở giai đoạn refinement, convolution và Depthwise Convolution được sử dụng nhằm tăng cường feature sau fusion trong khi hạn chế chi phí tính toán của decoder. Hiệu quả và mức đóng góp của từng thành phần được phân tích thông qua các thí nghiệm ablation trong Section 4.

4. Thực nghiệm và kết quả

4.1. Thiết lập thực nghiệm

Các thực nghiệm WeedsGalore được chạy trên Kaggle Notebook với NVIDIA Tesla T4, CUDA 12.8 và PyTorch 2.10.0+cu128. Ảnh WeedsGalore có kích thước 600×600; đầu ra gồm Background, Crop và Weed. Cấu hình huấn luyện dùng batch size 8, 4 data-loader workers, learning rate 0.0003 và tối đa 100 epochs. Optimizer là Adam; không dùng learning-rate scheduler, weight decay được đặt ở 0 và không có learning-rate warm-up.

MiT-B0 được khởi tạo từ checkpoint pretrained nvidia/mit-b0. Weighted Cross-Entropy được kết hợp với Soft Dice Loss theo tỉ lệ 0.7:0.3; class weights lần lượt là 0.9, 1.0 và 1.3 cho Background, Crop và Weed. Augmentation trong dataloader gồm xoay, lật và Gaussian noise. Với các thí nghiệm RGB-only và 5-band, seed 0–4 được huấn luyện độc lập và best_val.pth được chọn theo validation mIoU. Temperature được fit riêng trên validation của từng checkpoint rồi cố định khi tính ECE trên test; nhãn test không được dùng để chọn temperature.

Cấu hình chính không dùng spectral indices, spectral-guided module, attention module hoặc decoder DeepLabV3+. Trong thí nghiệm E5, RGB-only dùng in_channels=3 và giữ LowLevelRefine=True; mô hình đa phổ dùng in_channels=5 và cùng thiết lập loss/optimizer arguments. FLOPs được ước lượng bằng THOP. Log benchmark ghi inference time trung bình 100 lần đo trên Tesla T4. Vì vậy, latency và throughput được chúng tôi xem là số đo sơ bộ.

4.2. Kết quả thực nghiệm trên tập WeedsGalore

4.2.1. So sánh hiệu quả với phương pháp gốc

Bảng 2 tổng hợp mốc mIoU công bố của baseline và checkpoint đại diện dùng cho efficiency benchmark; split và nguồn của từng giá trị được ghi rõ trong bảng.

Bảng 2. Mốc accuracy theo split nguồn và chi phí tính toán của checkpoint benchmark.

Model	Input	mIoU (%)	Split / provenance	Params (M)	FLOPs (G)	Inference (ms)	Throughput (img/s)
ResNet50 + DeepLabV3+ [3]	5-band MSI	82.90	Official test set	39.76	173.82	116.57	8.58
Pretrained MiT-B0 + LowLevelRefine	5-band MSI	84.63	Validation; representative efficiency checkpoint	3.66	17.09	16.53	60.49

Bảng 2 trình bày hai mốc có nguồn khác nhau. Giá trị 82.90% là mIoU trên official test set được công bố trong WeedsGalore, trong khi 84.63% là validation mIoU của checkpoint đại diện dùng cho efficiency benchmark trong nghiên cứu này.

4.2.2. Phân tích đóng góp của các thành phần kiến trúc

Để khảo sát sơ bộ vai trò của các thành phần kiến trúc, chúng tôi so sánh cấu hình SegFormer-B0 cơ bản, cấu hình loại bỏ Multi-scale Feature Fusion và mô hình đầy đủ kết hợp cả Multi-scale Feature Fusion và LowLevelRefine. Kết quả được trình bày trong Bảng 3, đồng thời ghi rõ nguồn dữ liệu, số seed và cohort đánh giá của từng cấu hình nhằm làm rõ phạm vi so sánh.

Bảng 3. Kết quả ablation sơ bộ của các thành phần kiến trúc trên WeedsGalore.

Configuration	Multi-scale fusion	LowLevelRefine	Validation mIoU (%)	Validation provenance	Test mIoU (%)	Test provenance
SegFormer-B0 cơ bản	Có	Không	82.16	Seed 0; n=1	83.62	Seed 0; n=1
Không Multi-scale Feature Fusion	Không	Có	79.11	Seed 0; n=1	80.87	Seed 0; n=1
Mô hình đầy đủ	Có	Có	84.45 ± 0.16	Cohort validation 5 seed trước đây	85.49 ± 0.30	Cohort test 5 seed mới L1–L5

Ở seed 0, cấu hình SegFormer-B0 cơ bản đạt validation mIoU 82.16% và test mIoU 83.62%. Khi loại bỏ Multi-scale Feature Fusion và giữ lại LowLevelRefine, hiệu năng giảm xuống lần lượt còn 79.11% trên tập validation và 80.87% trên tập test. Trong khi đó, mô hình đầy đủ đạt validation mIoU 84.45 ± 0.16% và test mIoU 85.49 ± 0.30% theo các cohort được báo cáo.

Xét riêng các giá trị validation, mIoU của cấu hình cơ bản tại seed 0 thấp hơn 2.29 điểm phần trăm so với mức trung bình 84.45% của mô hình đầy đủ. Tuy nhiên, phép so sánh này được thực hiện giữa một kết quả đơn seed và kết quả trung bình của cohort năm seed trước đây; tương tự, kết quả test của mô hình đầy đủ thuộc cohort năm seed mới L1–L5. Do đó, các chênh lệch trên chỉ mang tính mô tả, chưa phải kết quả ablation ghép cặp trên cùng seed và cùng cohort, cũng chưa đủ để xác định độc lập mức đóng góp của từng thành phần kiến trúc.

Về chi phí tính toán, log của cấu hình không sử dụng Multi-scale Feature Fusion ghi nhận 3,596,499 tham số, 15.86 GFLOPs, thời gian suy luận 14.36 ms/ảnh và thông lượng 69.66 ảnh/giây. Các chỉ số này bổ sung góc nhìn về hiệu quả tính toán của cấu hình. Để đánh giá đáng tin cậy hơn vai trò của từng thành phần, các thí nghiệm tiếp theo cần được thực hiện với cùng cách chia dữ liệu, cùng quy trình huấn luyện và đánh giá, đồng thời sử dụng nhiều seed nhất quán giữa các cấu hình.

4.2.3. Ảnh hưởng của đầu vào đa phổ

Để đánh giá ảnh hưởng của NIR và RE, Bảng 4 so sánh các cấu hình RGB-only và 5-band trên cùng official test split WeedsGalore. Các giá trị được trình bày dưới dạng mean ± sample standard deviation qua năm seed; ở mỗi seed,

mIoU là trung bình số học của IoU ba lớp Background, Crop và Weed. ECE được tính trên test sau khi temperature đã fit riêng bằng validation cho từng checkpoint.

Bảng 4. So sánh RGB-only và RGB + NIR + RE trên test set WeedsGalore (mean ± sample std, n=5).

Input	Test mIoU (%)	Background IoU (%)	Crop IoU (%)	Weed IoU (%)	Test ECE after calibration
RGB-only	81.56 ± 0.67	98.18 ± 0.03	71.87 ± 1.28	74.63 ± 0.84	0.00771 ± 0.00046
RGB + NIR + RE	85.49 ± 0.30	98.63 ± 0.02	77.78 ± 0.62	80.06 ± 0.45	0.00579 ± 0.00030

Trên test set, mô hình 5-band đạt 85.49 ± 0.30% mIoU, cao hơn RGB-only (81.56 ± 0.67%) 3.93 điểm phần trăm. Crop IoU tăng 5.91 điểm, Weed IoU tăng 5.43 điểm và Background IoU tăng khoảng 0.45 điểm. Sau khi temperature được fit trên validation riêng cho từng seed, ECE test trung bình giảm từ 0.00771 ± 0.00046 với RGB-only xuống 0.00579 ± 0.00030 với 5-band. Kết quả ủng hộ lợi ích của NIR/RE trong thiết lập hiện tại; đây là so sánh hai cấu hình mô hình chứ không phải phép kiểm định thống kê trên các pixel độc lập.

4.2.4. Phân tích độ chính xác và hiệu quả

Bảng 5 so sánh các cấu hình theo đầu vào, trạng thái pretrained, nhánh refinement/decoder, split đánh giá và chi phí tính toán. Kết quả 82.90 của ResNet50 + DeepLabV3+ là official test value được công bố trong WeedsGalore [3]. Các kết quả SegFormer trong bảng là validation results của các checkpoint được lưu ở những lần chạy tương ứng, không phải trung bình cùng một cohort. Với ResNet34 + Spectral Branch, log giữ lại chưa đủ để xác nhận trạng thái pretrained và split của giá trị 82.24; vì vậy hàng này chỉ nên dùng làm mốc tham khảo cho đến khi đối chiếu được log gốc.

Bảng 5. So sánh accuracy–efficiency có ghi rõ modality, pretraining, refinement và split của mIoU.

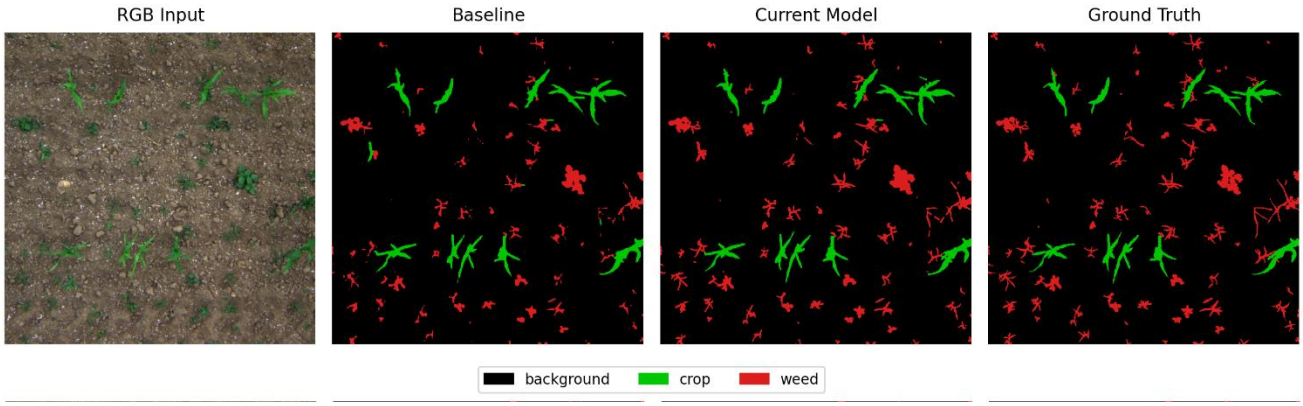
Model	Input	Pretrained	Refinement / decoder	mIoU (%) / evaluation split	Params (M)	FLOPs (G)	Inference (ms)	FPS
ResNet50 + DeepLabV3+ [3]	5-band MSI	Yes	As reported in official baseline	82.90	39.76	173.82	116.57	8.58
ResNet34 + Spectral Branch	RGB + NIR + RE	Not verified from retained log	Spectral branch + Lite-ASPP; exact run config unverified	82.24	21.94	22.78	12.41	80.60
SegFormer Scratch	5-band MSI	No	No LowLevelRefine	80.85 (validation)	3.38	3.84	6.78	147.53
SegFormer + MiT-B0	5-band MSI	Yes	No LowLevelRefine	82.16 (validation, seed 0)	3.46	3.49	10.13	98.71
MiT-B0 + LowLevelRefine	5-band MSI	Yes	LowLevelRefine = Yes	84.63 (validation checkpoint)	3.66	17.09	16.53	60.49

Trong benchmark validation, checkpoint MiT-B0 + LowLevelRefine đạt 84.63% mIoU, cao hơn 2.47 điểm so với SegFormer-B0 không refinement ở seed 0 (82.16%). Đây là đối chiếu giữa hai validation checkpoint, chưa phải trung bình paired qua năm seed. Số tham số tăng khoảng 5.8% (3.46M lên 3.66M), trong khi FLOPs tăng thêm 13.60G.

4.2.5. Đánh giá định tính kết quả phân đoạn

Hình 4.1 trình bày một số kết quả segmentation trên test set của WeedsGalore. Mô hình đề xuất duy trì tương đối tốt các đối tượng nhỏ, cấu trúc lá mảnh và các vùng Weed phân bố không liên tục. Sự khác biệt giữa các phương pháp rõ hơn ở những vùng có nhiều đối tượng nhỏ hoặc ranh giới Crop–Weed phức tạp.

Việc kết hợp hierarchical features từ MiT-B0 với spatial–spectral details từ nhánh tinh chỉnh đặc trưng giúp bổ sung thông tin ở độ phân giải cao trước bước prediction. Tuy nhiên, một số sai khác vẫn xuất hiện tại các vùng Weed nhỏ và những khu vực có đối tượng nằm gần nhau. Kết quả định tính trong Hình 4.1 được sử dụng như minh họa trực quan, trong khi mIoU và class-wise IoU là các chỉ số chính cho đánh giá định lượng.



Hình 4.1. Ví dụ kết quả phân đoạn trên tập test của WeedsGalore.

4.3. Phân tích hiểu chỉnh xác suất

4.3.1. Sai số hiệu chỉnh kỳ vọng

Độ tin cậy của xác suất dự đoán được đánh giá bằng Expected Calibration Error (ECE) [10]. Đối với mỗi seed của hai cấu hình RGB-only và 5-band, nhiệt độ T được tối ưu trên tập validation của checkpoint tương ứng, sau đó được cố định để đánh giá trên tập test. Nhãn test không được sử dụng trong quá trình tối ưu nhiệt độ. Bảng 6 trình bày kết quả đánh giá mô hình 5-band trên tập test qua năm random seeds. Các chỉ số được báo cáo gồm mIoU, IoU của từng lớp Background, Crop và Weed, cùng ECE sau calibration. Giá trị trung bình và độ lệch chuẩn mẫu được sử dụng để thể hiện hiệu năng và mức độ biến thiên giữa các lần chạy.

Bảng 6. Kết quả đánh giá mô hình 5-band trên tập test qua năm random seeds.

Seed	Test mIoU (%)	Background IoU (%)	Crop IoU (%)	Weed IoU (%)	ECE after calibration
L1 / seed 0	85.34	98.60	77.89	79.52	0.00570
L2 / seed 1	85.85	98.65	78.26	80.64	0.00548

Seed	Test mIoU (%)	Background IoU (%)	Crop IoU (%)	Weed IoU (%)	ECE after calibration
L3 / seed 2	85.43	98.61	77.87	79.82	0.00628
L4 / seed 3	85.10	98.65	76.71	79.93	0.00566
L5 / seed 4	85.73	98.63	78.16	80.39	0.00583
Mean ± sample std	85.49 ± 0.30	98.63 ± 0.02	77.78 ± 0.62	80.06 ± 0.45	0.00579 ± 0.00030

Với bộ checkpoint 5-band được chốt, test mIoU trung bình đạt 85.49 ± 0.30%, với độ biến thiên tương đối nhỏ giữa năm lần chạy. Lớp Background đạt IoU cao nhất, ở mức 98.63 ± 0.02%, trong khi hai lớp Crop và Weed có IoU trung bình lần lượt là 77.78 ± 0.62% và 80.06 ± 0.45%. ECE sau calibration đạt 0.00579 ± 0.00030%, cho thấy chỉ số hiệu chỉnh xác suất tương đối ổn định giữa các seed. Tiếp theo, Bảng 7 so sánh hiệu quả hiệu chỉnh xác suất giữa hai cấu hình RGB-only và 5-band. Bảng liệt kê nhiệt độ $\boldsymbol{T}$ được tối ưu trên validation cho từng seed và ECE trung bình sau calibration trên tập test, qua đó đánh giá sự khác biệt về độ tin cậy xác suất giữa hai cấu hình đầu vào.

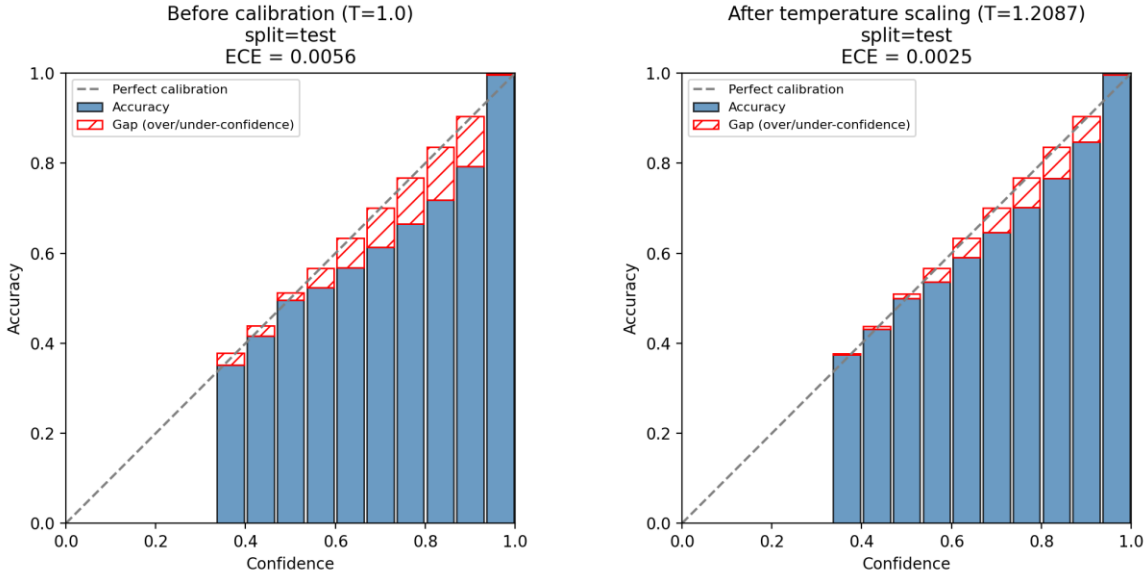
Bảng 7. Temperature Scaling được fit trên validation và ECE trên test qua 5 random seeds.

Input configuration	T fitted on validation (seeds 0–4)	Test ECE after calibration (mean ± sample std)
RGB-only	1.2339; 1.2009; 1.1687; 1.1930; 1.2571	0.00771 ± 0.00046
RGB + NIR + RE	1.2087; 1.2376; 1.2140; 1.2168; 1.1790	0.00579 ± 0.00030

So với cấu hình RGB-only, cấu hình 5-band có ECE trung bình thấp hơn, từ 0.00771 xuống 0.00579, tương ứng mức giảm khoảng 24.9%. Kết quả này cho thấy cấu hình 5-band có độ phù hợp giữa confidence dự đoán và độ chính xác thực tế tốt hơn theo chỉ số ECE trong giao thức đánh giá được sử dụng. Tuy nhiên, ECE phản ánh độ tin cậy xác suất chứ không trực tiếp đo chất lượng phân đoạn; do đó, cần xem xét kết quả này cùng với các chỉ số mIoU và IoU từng lớp để đánh giá tổng thể mô hình.

4.3.2. Biểu đồ tin cậy

Để đánh giá mức độ phù hợp giữa độ tin cậy dự đoán và độ chính xác thực tế của mô hình phân đoạn ảnh đa phổ, nghiên cứu sử dụng biểu đồ tin cậy (reliability diagram) kết hợp với chỉ số Expected Calibration Error. ECE được tính bằng trung bình có trọng số của độ chênh lệch tuyệt đối giữa độ tin cậy trung bình và độ chính xác thực tế trong các khoảng xác suất dự đoán. Giá trị ECE càng nhỏ cho thấy mức độ hiệu chỉnh xác suất của mô hình càng tốt. Thí nghiệm được thực hiện trên tập kiểm thử (test set) với năm seed, sử dụng các checkpoint tương ứng của mô hình SegFormer với backbone MiT-B0 và đầu vào năm kênh phổ. Biểu đồ tin cậy được xây dựng với 15 khoảng xác suất có độ rộng bằng nhau. Với mỗi seed, ECE được tính trước và sau khi áp dụng Temperature Scaling, sử dụng nhiệt độ hiệu chỉnh tương ứng. Phương pháp này điều chỉnh phân phối xác suất đầu ra bằng cách chia logits cho nhiệt độ trước khi áp dụng hàm softmax, qua đó thay đổi độ tin cậy của dự đoán mà không làm thay đổi lớp dự đoán có xác suất lớn nhất. Hình 4.2 minh họa biểu đồ tin cậy của mô hình SegFormer MiT-B0 trên dữ liệu đa phổ năm kênh trước và sau khi hiệu chỉnh bằng Temperature Scaling, với seed 0, nhiệt độ (T=1.2087) và 15 khoảng xác suất (bins).



Hình 4.2. Biểu đồ tin cậy của mô hình SegFormer MiT-B0 sử dụng dữ liệu đa phổ 5 kênh trước và sau hiệu chuẩn bằng Temperature Scaling trên tập test (seed 0, (T=1.2087), 15 bins). ECE giảm từ 0.005625 trước hiệu chuẩn xuống 0.002454 sau hiệu chuẩn.

Quan sát Hình 4.2 cho thấy sau khi áp dụng Temperature Scaling, ECE giảm từ 0,005625 xuống 0,002454, tương ứng mức giảm tương đối khoảng 56,37%. Kết quả này cho thấy sự phù hợp giữa độ tin cậy dự đoán và độ chính xác thực tế được cải thiện đối với lần chạy seed 0. Nếu xét trên cả năm seed, ECE trung bình giảm từ 0,005618 trước hiệu chỉnh xuống 0,002669 sau hiệu chỉnh, tương ứng mức giảm khoảng 52,51% khi tính từ hai giá trị trung bình. ECE sau hiệu chỉnh thấp hơn ECE trước hiệu chỉnh ở cả năm lần chạy, cho thấy kết quả cải thiện có tính nhất quán trong các thí nghiệm được thực hiện. Đối với các hệ thống phân tích ảnh nông nghiệp, việc cải thiện độ hiệu chỉnh xác suất có thể hỗ trợ đánh giá mức độ tin cậy của kết quả phân đoạn và xác định những trường hợp cần được kiểm tra thêm. Cần lưu ý rằng mức giảm ECE phản ánh sự cải thiện về độ hiệu chỉnh xác suất, không đồng nghĩa với việc độ chính xác phân đoạn tăng lên, bởi Temperature Scaling không làm thay đổi lớp dự đoán có xác suất lớn nhất tại mỗi pixel

4.4. Kết quả thực nghiệm trên tập PhenoBench

PhenoBench được dùng trong một thực nghiệm huấn luyện độc lập với RGB input. Mô hình được huấn luyện trên train split của PhenoBench với crop_size=512; cùng checkpoint best_val.pth được đánh giá trên validation split theo hai giao thức: resize ảnh về 512×512 và đánh giá ở độ phân giải gốc 1024×1024 (eval_native_resolution=True). Vì vậy, hai hàng trong Bảng 8 phản ánh khác biệt về độ phân giải khi đánh giá, không phải hai mô hình được huấn luyện độc lập với kích thước đầu vào khác nhau. Nhãn của test split PhenoBench không được công khai, do đó kết quả này là validation-only.

Bảng 8. Validation results trên PhenoBench theo độ phân giải đầu vào.

Độ phân giải	mIoU (%)	Crop IoU (%)	Weed IoU (%)	Soil/BG IoU (%)
512×512 (resize)	85.12	93.84	62.25	99.26

1024×1024 (độ phân giải gốc)	89.83	95.86	74.14	99.48
	+4.71	**+2.02**	**+11.89**	**+0.22**

Trên cùng checkpoint, đánh giá validation sau khi resize ảnh về 512×512 cho mIoU 85.12%, trong khi đánh giá ở độ phân giải gốc 1024×1024 cho mIoU 89.83% (+4.71 điểm). Crop IoU tăng 2.02 điểm, Weed IoU tăng 11.89 điểm và Soil/BG IoU tăng 0.22 điểm. Do cả hai kết quả đều được tính trên cùng validation split, chênh lệch này phản ánh ảnh hưởng của giao thức độ phân giải khi suy luận/đánh giá; không nên diễn giải là mức tăng do huấn luyện một mô hình 1024×1024 riêng. Mức tăng lớn nhất ở Weed IoU gợi ý rằng giữ độ phân giải gốc có thể giúp bảo toàn chi tiết đối tượng nhỏ, nhưng cần đối chiếu với chi phí bộ nhớ và thời gian suy luận trước khi kết luận về deployment.

Bảng 9 cung cấp các mốc tham khảo từ ERFNet và DeepLabV3+ được công bố trên official test set PhenoBench. Kết quả của mô hình trong nghiên cứu này là validation result vì nhãn của test split không được công khai để tính metric cục bộ. Do đó, các hàng trong bảng thuộc những split khác nhau và chỉ được trình bày như thông tin tham khảo; không dùng bảng này để tuyên bố mô hình đề xuất vượt baseline hoặc so sánh trực tiếp hiệu năng.

Bảng 9. Mốc tham khảo trên PhenoBench; các split khác nhau nên không so sánh trực tiếp.

Phương pháp	**Tập đánh giá**	**mIoU (%)**	**Crop IoU (%)**	**Weed IoU (%)**	**Soil/BG IoU (%)**
ERFNet	Official test	85.98	94.30	64.37	99.28
DeepLabV3+	Official test	85.97	94.07	64.59	99.25
Ours	Validation (độ phân giải gốc)	**89.83**	**95.86**	**74.14**	**99.48**

Cấu hình PhenoBench được xác nhận từ lệnh chạy gồm dataset_type=phenobench, train split có 1,407 ảnh, RGB input (in_channels=3), num_classes=3, pretrained_backbone=True (MiT-B0 pretrained), batch size 8, 4 workers, crop_size=512, learning rate 0.0003, class weights [0.9, 1.0, 1.3], Weighted Cross-Entropy + Soft Dice (dice_weight=0.3) và tối đa 100 epochs. Training implementation dùng Adam, không có scheduler, weight decay bằng 0 và không có learning-rate warm-up. Dataset mapping gộp ID 3 (partial-crop) vào Crop và ID 4 (partial-weed) vào Weed; target báo cáo gồm ba lớp Background/Soil, Crop và Weed. Checkpoint best_val.pth được chọn tại epoch 94 với mIoU 85.12% khi đánh giá ở 512×512. Khi chạy evaluate.py với --eval_native_resolution=True, cùng checkpoint đạt 89.83% mIoU trên validation split ở độ phân giải gốc 1024×1024 (Background/Soil IoU 99.48%, Crop IoU 95.86%, Weed IoU 74.14%). Đây không phải kết quả test: nhãn test PhenoBench không được công khai, nên không thể tính test mIoU cục bộ. Hai kết quả ở Bảng 8 là validation results trên cùng split nhưng khác giao thức độ phân giải; Bảng 9 chỉ cung cấp mốc official-test đã công bố và không cho phép kết luận hơn hoặc kém trực tiếp.

5. Kết luận

Nghiên cứu của chúng tôi đã khảo sát mô hình phân đoạn Crop–Weed trên ảnh UAV đa phổ dựa trên SegFormer với encoder MiT-B0 pretrained, kết hợp hợp nhất đặc trưng đa tỉ lệ và nhánh Low-Level Feature Refinement xử lý trực tiếp đầu vào năm băng R, G, B, NIR và RE. Trên bộ checkpoint 5-band được đánh giá qua năm random seeds trên

WeedsGalore, mô hình đạt mIoU trung bình 85,49 ± 0,30%, cao hơn cấu hình RGB-only 3,93 điểm phần trăm. Đáng chú ý, Crop IoU và Weed IoU tăng lần lượt 5,91 và 5,43 điểm phần trăm, cho thấy việc bổ sung thông tin phổ NIR và RE có lợi cho phân đoạn các lớp mục tiêu trong thiết lập thực nghiệm này. Về độ tin cậy xác suất, Temperature Scaling với nhiệt độ được tối ưu riêng trên tập validation cho từng checkpoint giúp đánh giá calibration trên tập test mà không sử dụng nhãn test để hiệu chỉnh. Cấu hình 5-band đạt ECE trung bình 0,00579 ± 0,00030, thấp hơn mức 0,00771 ± 0,00046 của cấu hình RGB-only. Về độ phức tạp, mô hình có 3,66 triệu tham số và 17,09 GFLOPs, cho thấy kiến trúc có quy mô tương đối gọn so với mốc ResNet50–DeepLabV3+ được sử dụng trong nghiên cứu. Tuy nhiên, chi phí tính toán vẫn cao hơn SegFormer-B0 cơ bản; đồng thời, kết quả ablation loại bỏ Low-Level Feature Refinement hiện chưa đủ để xác định riêng mức đóng góp của nhánh này qua nhiều lần chạy độc lập. Trên PhenoBench, mô hình được huấn luyện độc lập và đạt 89,83% mIoU trên tập validation khi đánh giá ở độ phân giải gốc 1024 × 1024. Do nhãn test của bộ dữ liệu này không được công khai trong thiết lập sử dụng, kết quả trên chỉ phản ánh hiệu năng validation, không phải kết quả test hay đánh giá chuyển giao trực tiếp từ WeedsGalore. Vì vậy, kết quả PhenoBench được xem là một thực nghiệm bổ sung trên bộ dữ liệu khác, thay vì bằng chứng về khả năng vượt các baseline được báo cáo trên official test. Từ những thí nghiệm trên, kết quả cho thấy cấu hình SegFormer/MiT-B0 với đầu vào năm băng đạt hiệu năng phân đoạn và độ tin cậy xác suất tốt hơn cấu hình RGB-only trong các điều kiện đã khảo sát. Trong hướng nghiên cứu tiếp theo, chúng tôi dự kiến khảo sát khả năng khai thác thông tin từ ảnh vệ tinh nhằm tăng cường hiệu quả phân đoạn cây trồng và cỏ dại trên ảnh UAV đa phổ. Do ảnh vệ tinh cung cấp thông tin ở phạm vi không gian rộng, việc kết hợp thông tin giữa ảnh vệ tinh và ảnh UAV có thể mở ra hướng bổ sung ngữ cảnh không gian và đặc trưng phổ cho mô hình phân đoạn ở độ phân giải cao. Trọng tâm là tìm hiểu các phương pháp tích hợp thông tin đa nguồn phù hợp, tận dụng ưu thế bao phủ rộng của ảnh vệ tinh và khả năng thể hiện chi tiết của ảnh UAV, hướng tới nâng cao độ chính xác và tính ổn định của mô hình trong các điều kiện canh tác khác nhau.

Tài liệu tham khảo

[1] F. Wolff, T. H. M. Kolari, M. Villoslada, T. Tahvanainen, P. Korpelainen, P. A. P. Zamboni, and T. Kumpula, "RGB vs. Multispectral Imagery: Mapping Aapa Mire Plant Communities with UAVs," *Ecological Indicators*, vol. 148, Art. no. 110140, 2023, doi: 10.1016/j.ecolind.2023.110140.

[2] T. Adão, J. Hruška, L. Pádua, J. Bessa, E. Peres, R. Morais, and J. J. Sousa, "Hyperspectral Imaging: A Review on UAV-Based Sensors, Data Processing and Applications for Agriculture and Forestry," *Remote Sensing*, vol. 9, no. 11, Art. no. 1110, 2017, doi: 10.3390/rs9111110.

[3] E. Celikkan, T. Kunzmann, Y. Yeskaliyev, S. Itzerott, N. Klein, and M. Herold, “WeedsGalore: A Multispectral and Multitemporal UAV-Based Dataset for Crop and Weed Segmentation in Agricultural Maize Fields,” in *Proceedings of the Winter Conference on Applications of Computer Vision (WACV)*, 2025, pp. 4767–4777, doi: 10.1109/WACV61041.2025.00467.

[4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[5] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, “Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 801–818, doi: 10.1007/978-3-030-01234-2_49.

[6] G. Castellano, P. De Marinis, and G. Vessio, “Weed Mapping in Multispectral Drone Imagery Using Lightweight Vision Transformers,” *Neurocomputing*, vol. 562, Art. no. 126914, 2023, doi: 10.1016/j.neucom.2023.126914.

[7] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, “SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers,” in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 12077–12090.

[8] Q. Li, H. Yuan, T. Fu, Z. Yu, B. Zheng, and S. Chen, “Multispectral Semantic Segmentation for UAVs: A Benchmark Dataset and Baseline,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 62, Art. no. 1002117, 2024, doi: 10.1109/TGRS.2024.3457674.

[9] J. Weyler, F. Magistri, E. Marks, Y. L. Chong, M. Sodano, G. Roggiolani, N. Chebrolu, C. Stachniss, and J. Behley, “PhenoBench: A Large Dataset and Benchmarks for Semantic Image Interpretation in the Agricultural Domain,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 12, pp. 9583–9594, 2024, doi: 10.1109/TPAMI.2024.3419548.

[10] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On Calibration of Modern Neural Networks,” in *Proceedings of the 34th International Conference on Machine Learning*, PMLR, vol. 70, 2017, pp. 1321–1330.

[11] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu, and N. Sang, “BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 334–349, doi: 10.1007/978-3-030-01261-8_20.